EventB PO Dataset — ชุดสำหรับเทรน AI

198 โมเดล · label จาก Rodin + Atelier B (ML/PP) · ทุกโมเดลเป็นผลของสูตรแปลง ChronoSeq-B

198	119 / 79	4,236	238
โมเดล	pass / fail	PO ทั้งหมด	PO ที่พิสูจน์ไม่ได้

1. ต้องอัปอะไรไปเทรน

อัป 2 ไฟล์นี้ไปเทรน (fine-tune)
`upload/train.jsonl` (137 โมเดล) — ใช้เทรน
`upload/val.jsonl` (30 โมเดล) — ใช้ตรวจระหว่างเทรน (validation file)

ห้ามอัป `upload/test.jsonl` (31 โมเดล) — เก็บไว้วัดผลหลังเทรนเท่านั้น

ไฟล์ทั้ง 3 เป็นรูปแบบ chat (`messages`: system / user / assistant) ใช้กับ OpenAI fine-tuning, Hugging Face (TRL / SFTTrainer) และเครื่องมือส่วนใหญ่ได้ตรง ๆ ถ้าเครื่องมือที่ใช้ต้องการรูปแบบอื่น ใช้ `data/dataset.jsonl` แปลงต่อได้

ถ้าจะทำ	ใช้ไฟล์
Fine-tune LLM	`upload/train.jsonl` + `upload/val.jsonl`
วัดผลหลังเทรน	`upload/test.jsonl` — ให้โมเดลตอบจากข้อความ user แล้วเทียบกับคำตอบ assistant
RAG (ค้นโมเดลที่คล้ายมาเป็นตัวอย่าง)	ทำดัชนีจาก train ใน `data/dataset.jsonl` (คอลัมน์ `model` + label) แล้วทดสอบกับ test
ML ทั่วไปจาก feature (ไม่ใช้ LLM)	`csv/summary.csv` (คอลัมน์ n_* = input, total_po / failed = เป้าหมาย)

2. ตัวอย่างข้อมูล 1 รายการ


```
{
 "id": "model_013",
 "messages": [
  {
   "role": "system",
   "content": "You are an Event-B proof-obligation analyst. ... Answer with JSON only."
  },
  {
   "role": "user",
   "content": "How many proof obligations does this model have, how many are discharged, how many
fail, and which ones fail?\n\nEvent-B model:\n```\nCONTEXT CourseEnrollmentContext\nSETS\n    Obje
cts; Messages; DataMessages\nCONSTANTS\n    Advisor, Portal, Registrar, Student\n    browseCourses
_1, courseList_2, enrollRequest_3, checkPrereq_4, prereqOK_5, requestApproval_6, approved_7, enrol
lConfirm_8\n    courseID, courses, enrollID\nAXIOMS\n    axm1: partition(Objects, {Advisor}, {Port
al}, {Registrar}, {Student})\n    axm2: part\n... (ต่อจนจบโมเดล) ...\n```"
  },
  {
   "role": "assistant",
   "content": "{\"total_po\": 20, \"discharged\": 18, \"failed\": 2, \"failed_pos\": [\"INITIALISA
```

```
TION/act12/FIS\", \"INITIALISATION/act15/FIS\"]}"
  }
 ]
}
```

คำตอบ (assistant) = จำนวน PO ทั้งหมด, ที่พิสูจน์ได้, ที่ล้ม และชื่อ PO ที่ล้ม — ชื่อ PO อ่านแบบ `<event>/<label>/<ชนิด>` เช่น `INITIALISATION/act12/FIS`

3. โครงสร้าง folder

```
EventB_PO_Training/
├── README.pdf                ← ไฟล์นี้
├── upload/                   ← ไฟล์สำหรับเทรน
│   ├── train.jsonl
│   ├── val.jsonl
│   └── test.jsonl            ← ห้ามใช้เทรน
├── data/
│   ├── dataset.jsonl         ← ทุกโมเดล: ข้อความ Event-B + feature + label + topic + split
│   ├── po_details.jsonl      ← ผลราย PO (ผ่าน / ไม่ผ่าน)
│   └── split.csv             ← โมเดลไหนอยู่ train / val / test
├── csv/
│   ├── summary.csv           ← ตัวเลขต่อโมเดล (feature + label)
│   ├── pass_fail_list.csv    ← pass / fail ต่อโมเดล
│   └── model_categories.csv  ← หัวข้อ + จุดผิดใน diagram (ใช้วิเคราะห์ ห้ามเป็น input)
├── models/model_001 … model_198/
│   ├── model.txt             ← Event-B (input)
│   ├── label.json            ← total / discharged / failed
│   ├── po_details.json       ← ผลราย PO
│   └── features.json
├── by_topic/                 ← โมเดลชุดเดียวกัน แยกตามหัวข้อ และผล Rodin
│   ├── 01_Finance_and_Payment/
│   │   ├── list.csv          ← รายชื่อ + ผล ของหัวข้อนี้
│   │   ├── pass/model_003_ATMWithdrawal/ …
│   │   └── fail/model_004_BankTransfer/ …
│   └── … (11 หัวข้อ)
└── FLOW.pdf · FLOW.png       ← แผนภาพขั้นตอนการดำเนินงาน
```

4. การแบ่ง train / val / test

แบ่ง 70 / 15 / 15 แบบรักษาสัดส่วน pass/fail และชนิดของ PO ที่ล้มให้เท่ากันทุกชุด (ใช้ seed คงที่ — สร้างใหม่ได้ผลเดิม) · model_001 (Payment) อยู่ใน test เสมอ

ชุด	โมเดล	pass	fail: FIS	fail: WD	fail: FIS+WD	PO
train	137	82	38	13	4	2,959
val	30	18	8	3	1	638
test	31	19	8	3	1	639

5. สถิติ

PO ต่อโมเดล: ต่ำสุด 11 · มัธยฐาน 19 · สูงสุด 50 · ความยาวข้อความ Event-B เฉลี่ย 10,277 ตัวอักษร

ชนิด PO	ความหมาย	ทั้งหมด	ล้ม

`INV`	invariant ยังจริงหลัง event	3,362	0
`FIS`	action :∈ มีค่าให้เลือก	725	89
`WD`	สูตรคำนวณได้ (เช่น mod)	149	149

หัวข้อ	pass	fail	รวม	train / val / test
การเงินและการชำระเงิน	10	4	14	9 / 1 / 4
สุขภาพและการแพทย์	12	14	26	20 / 4 / 2
การเดินทางและยานพาหนะ	18	8	26	22 / 3 / 1
โลจิสติกส์และคลังสินค้า	9	5	14	7 / 3 / 4
บ้านและอาคารอัจฉริยะ	11	10	21	15 / 3 / 3
อุตสาหกรรม พลังงาน และโครงสร้างพื้นฐาน	8	5	13	7 / 4 / 2
ค้าปลีก อาหาร และ e-commerce	9	5	14	9 / 3 / 2
การจอง ที่พัก และกิจกรรม	13	6	19	11 / 5 / 3
การศึกษาและบริการภาครัฐ	10	7	17	9 / 3 / 5
ไอทีและบริการดิจิทัล	10	9	19	15 / 1 / 3
เกษตรและสิ่งแวดล้อม	9	6	15	13 / 0 / 2

6. ข้อควรรู้ก่อนเทรน

- **input มีแค่ข้อความ Event-B** (`model.txt`) — ห้ามใส่คอลัมน์ใน `model_categories.csv` เช่น ชนิดจุดผิด หรือ expected เพราะเป็นเฉลย
- **PO ที่ล้มมีแค่ FIS กับ WD** — สูตรแปลงทำให้ INV ไม่ล้มจาก diagram โมเดลที่เทรนจะเรียนรู้รูปแบบ `:∈ a..b` ที่ a > b และ `mod` กับตัวนับ loop ซึ่งตรงกับพฤติกรรมจริงของสูตรแปลง แต่ไม่ครอบคลุมความผิดแบบอื่น
- **label ขึ้นกับ prover** — ทั้งชุดใช้ Rodin + Atelier B (ML/PP) ค่าเดียวกัน ถ้ารันด้วย prover อื่นจำนวนที่พิสูจน์ได้อาจต่าง
- **ข้อความยาว** — เฉลี่ยราว 3,425 token ต่อโมเดล (ยาวสุดราว 6,115 token) ควรเลือก LLM ที่รับ context ได้อย่างน้อย 8k
- สร้าง folder นี้ใหม่ได้ด้วย `python tools/make_release.py` ใน EventB_PO_Dataset